LEANAGENT · 4주차 연구 발표

Lean 증명 최적화 하네스 실험과 구조 탐색

1차 하네스 / 프롬프트·피드백 비교 / Astra 자유 탐색

실험 조건, 관측 결과와 해석 범위 · 2026.10.25 저장 기록 기준

연구 목적

하네스가 실험의 입력과 검증 절차를 고정한다

대회 과제: 같은 Lean 명제를 더 짧고 낮은 비용의 증명으로 바꾸기

에이전트가 담당	하네스가 담당
새 증명 본문을 제안	문제·환경·예산을 고정하고 검증
실패 피드백을 보고 다음 후보 탐색	유효성·비용·실패 이유와 상태를 저장
실행마다 서로 다른 경로로 탐색할 수 있음	같은 선택 규칙으로 후보를 비교·재검증

이번 초점은 조건을 일관되게 적용하고 결과를 다시 확인하는 데 있다

두 문제는 식의 변수와 수열의 반복을 다룬다

P01 / Strata / substOldPostSubset

치환 뒤 등장하는 변수는 원래 식의 변수와 새 변수 h1 안에 포함된다.

P13 / Mathlib / putnam_1964_a4

주어진 점화식을 따르는 유계 정수 수열은 어느 시점부터 같은 패턴이 반복된다.

바꾸는 것은 증명 본문이며 명제·가정·import·주변 소스는 유지한다

실험 단위

2개 실행에서 후보 20개를 제출할 수 있다

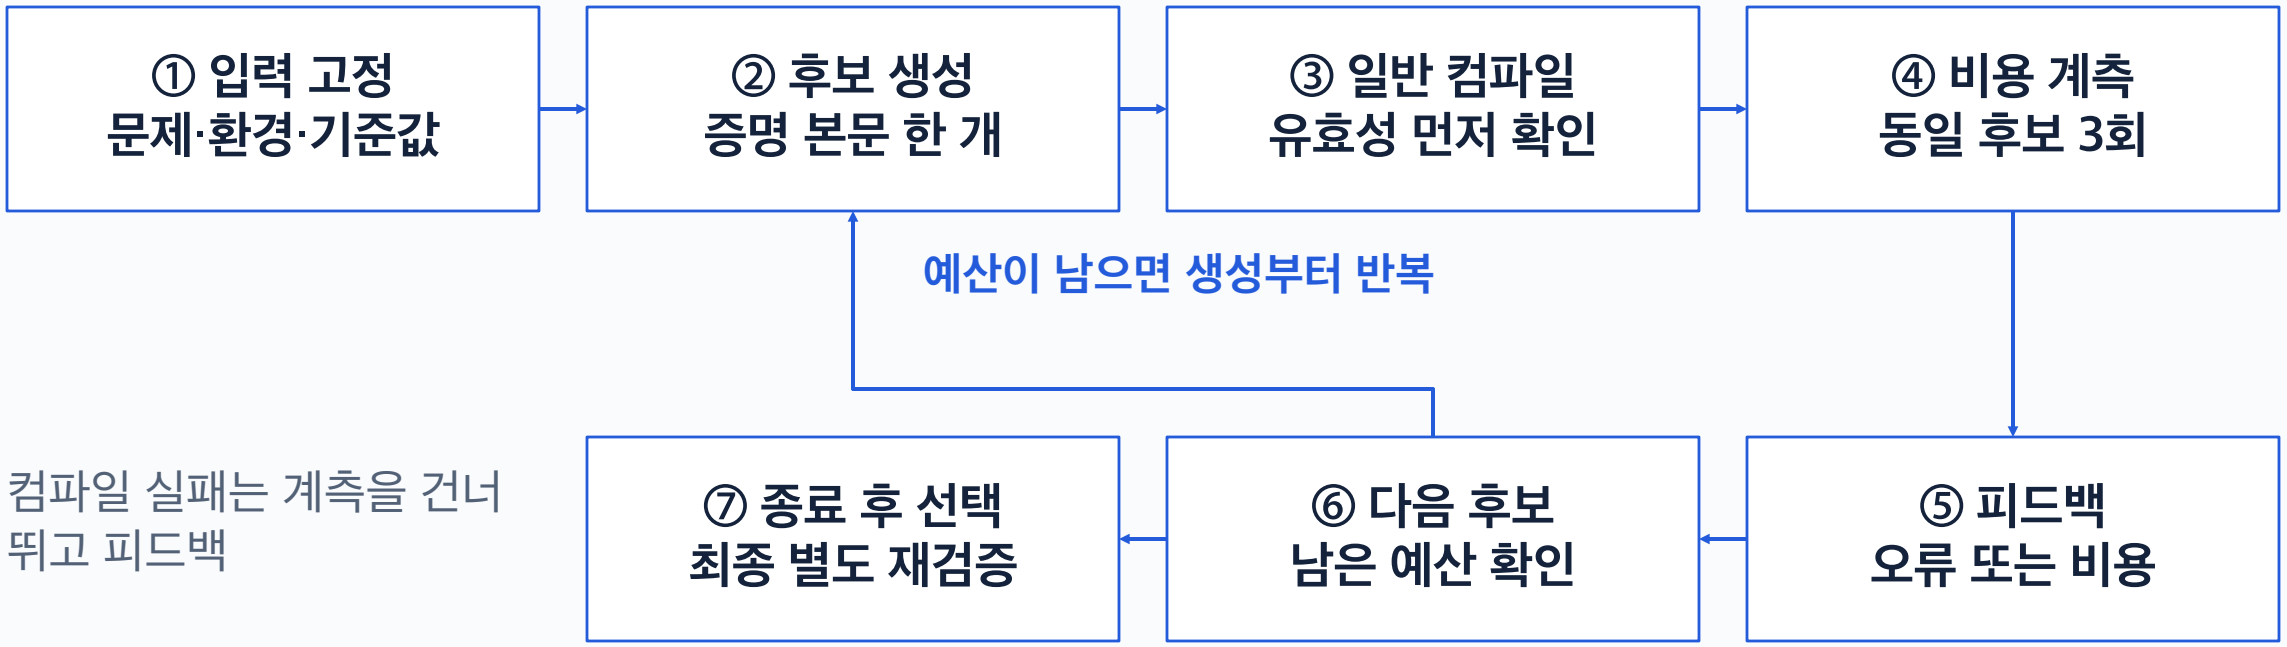
용어	이 발표에서 세는 단위	예
실행 (run)	독립 에이전트가 처음부터 끝까지 수행한 실험 한 번	에이전트 2개 = 실행 2개
후보 (proposal)	한 실행 안에서 제출한 증명 본문 한 개	각 실행이 10개 = 후보 20개
계측 컴파일	한 후보의 비용을 재기 위한 Lean 실행	같은 후보를 3회 계측

후보 제출 수·내부 모델 호출 수·Lean 컴파일 횟수는 서로 다르다

내부 모델 호출 수와 요금은 이번 어댑터에서 관측하지 못했다

후보 하나가 지나는 과정

한 후보를 통과시킨 뒤 같은 후보를 3회 계측한다



계측 3회는 같은 후보의 반복 측정이며, 새 후보 3개를 생성한 것이 아니다

결과를 구분하는 기준

유효성·비용 개선·최종 검증은 다른 결과다

질문	무엇을 확인하나	실제 예
증명이 유효한가	명제를 유지하고 컴파일·공리 검사를 통과했나	초기 P01의 33토큰 후보는 유효
비용이 개선됐나	원본 또는 비교 후보보다 결합 비용이 낮나	그 P01 후보는 Lean 작업량(HB) 증가로 불리
최종 검증도 통과했나	선택 후 별도 재실행에서도 검증을 마쳤나	초기 P13 확장 2개 실행은 최종 timeout

최종 검증은 선택본에 대한 추가 확인이며, 탐색 중 측정과 따로 보고한다

수행한 하네스 실험

이번 하네스 실험은 34개 실행·312개 후보다

묶음	문제	바꾼 조건	실행 / 후보
초기	P01·P13	기본 지침으로 3회 탐색	4 / 12
예산 확장	P13	후보 예산 3회에서 10회로	2 / 20
프롬프트 비교	P13	기본 A와 추가 지침 B1~B4	10 / 100
같은 지침 비교	P01	P13과 같은 A·B1~B4	10 / 100
오류 피드백 비교	P01·P13	기존 L과 구조화 S	8 / 80

OpenRouter 비교는 미실시 · Astra 자유 탐색은 다른 설계의 연구로 뒤에서 소개

문제와 측정 규칙을 비교 조건 안에서 고정했다

항목	고정한 내용 또는 명시적으로 바꾼 항목
문제·소스	문제 안에서 명제·원본 증명·import·주변 소스 고정
Lean·라이브러리	Lean 4.26.0, 문제별 라이브러리 commit 고정
프롬프트	기본 A 유지, 지침 실험에서만 B1~B4 추가
후보 예산	비교 묶음 안에서 고정, 실패도 1개 소비
피드백	성공 피드백 공통, 오류 정책 실험에서만 L·S 변경
메모리 정책	실행별 새 문맥, 실행 안의 대화·현재 최선·직전 결과 유지
검증 방식·제한	일반 1회 + 계측 3회 중앙값, 동일 묶음의 시간 제한 고정

모델 ID·sampling seed·숨은 문맥은 관측하거나 고정하지 못했다

초기와 후속 실험은 기준값·시간 제한이 달랐다

구분	초기·P13 예산 확장	후속 프롬프트·피드백 비교
원본 기준값	각 실행의 원본 측정값을 요청·분모로 사용	문제별 원본 기준값을 공통 고정
별도 원본 측정	실행의 기준값으로 사용	준비 상태 확인용으로 따로 보존
초 단위 timeout	Lean invocation마다 180초	각 invocation마다 420초
해석	독립적인 초기 관측	새로 실행한 같은 묶음의 A·B 또는 L·S 비교

묶음 사이의 차이를 프롬프트 하나의 효과로 해석하지 않는다

HB는 시간 대신 Lean의 작업량을 나타낸다

지표	측정하는 것	구분해야 할 것
증명 토큰	소스 본문의 단어·기호를 정한 규칙으로 계산	모델 과금 토큰, 줄 수와 다름
raw HB	Lean의 대상 정리 처리에서 계측한 작업량 지표	초 단위 시간·메모리 사용량과 별개
반복 측정	같은 후보를 새 프로세스 3회로 재측정	세 raw HB 값의 중앙값을 사용

같은 버전·원문 문맥에서 원본과 후보를 비교한다

HB의 대상 구간에는 명제 타입 처리도 포함된다

원본을 1로 둔 비용이 낮을수록 더 좋은 후보다

종합 비용 = ½ × (후보 토큰 / 원본 토큰 + 후보 raw HB / 원본 raw HB)

설명용 가상 후보	남은 길이 비율	남은 HB 비율	종합 비용
원본	1.00	1.00	1.00
후보 A	**0.20**	**0.10**	**0.15**
후보 B	0.10	0.50	0.30

0.15는 원본 비용의 15%가 남았다는 뜻 · 유효 후보 중 이 값이 가장 낮은 것을 선택

3·6·10회는 한 실행의 중간 관측이다

모든 10회 실험은 시작할 때부터 후보 예산이 10개임을 알았다

표현	읽는 방법
3회·6회·10회 비용	같은 실행의 각 시점까지 찾은 최선 비용
평균 곡선	조건별 두 실행의 같은 회차 최선 비용을 평균
수평 구간	새 후보가 실패하거나 이전 최선보다 개선되지 않음
편차	두 실행의 원값과 최소~최대 범위를 평균 옆에 제시

전체 예산을 3·6·10개로 각각 배정한 별도 실행의 비교가 아니다

초기 P01은 유효 후보를 얻어도 비용을 못 줄였다

기본 지침 · P01/P13 각각 독립 실행 2개 · 실행당 후보 3개 · 180초 제한

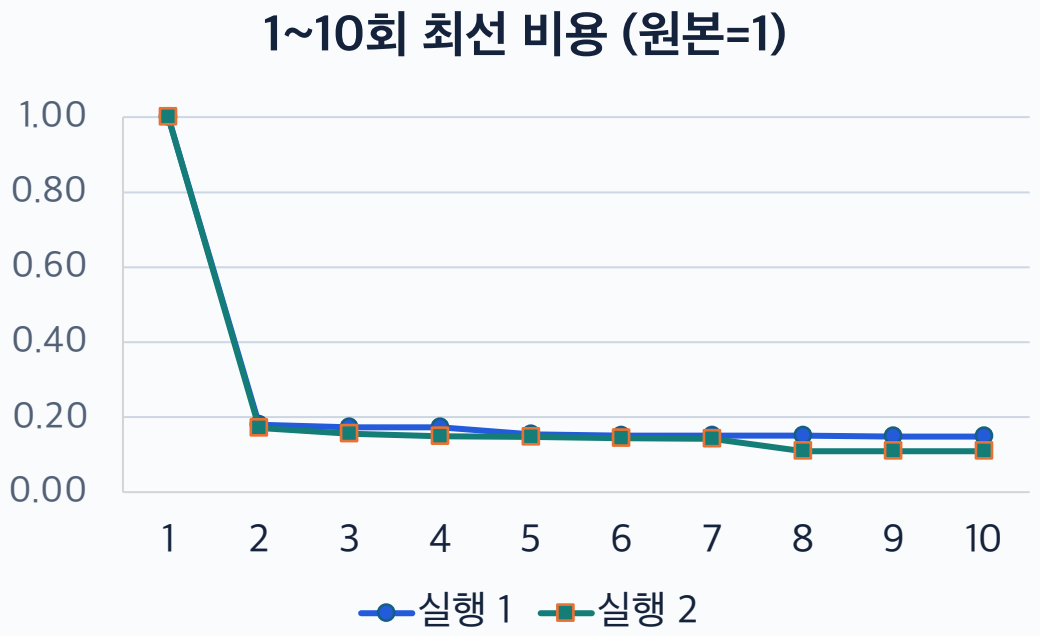
실행	유효 / 제안	3회 선택 비용	선택 토큰	최종 검증
P01-r1	1 / 3	1.0000	313	통과
P01-r2	2 / 3	1.0000	313	통과
P13-r1	2 / 3	0.1317	415	통과
P13-r2	2 / 3	0.1987	618	통과

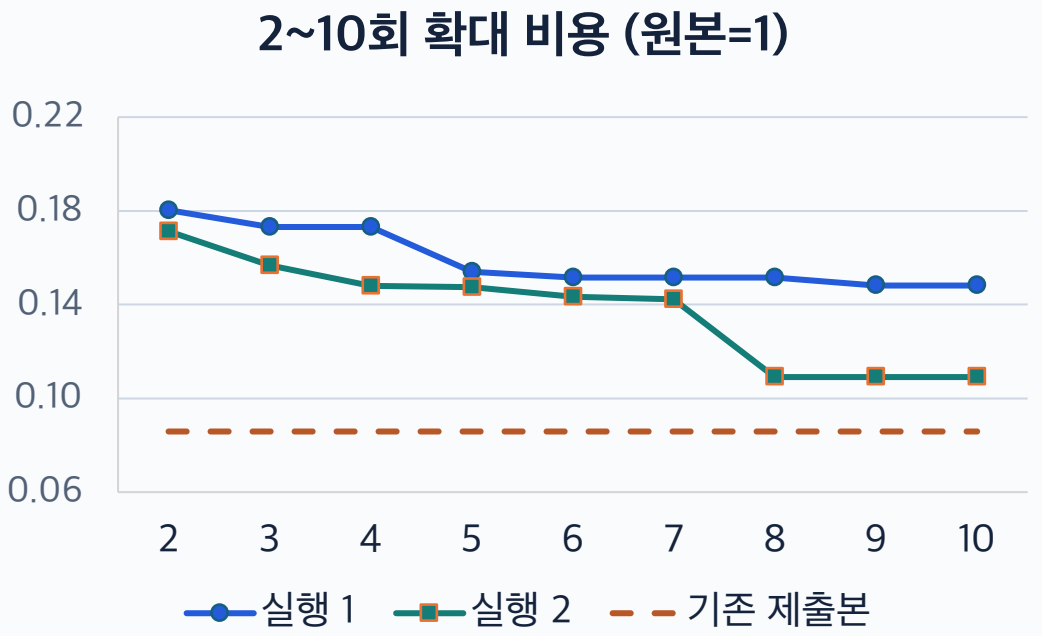
관측: P01은 두 실행 모두 원본 313토큰 유지, P13은 두 실행 모두 원본 대비 비용 개선.

해석 범위: 유효 후보가 있어도 비용 개선은 별개다. 초기 4개 선택본의 최종 검증은 모두 통과했다.

초기 P13의 추가 탐색은 비용을 더 낮췄다

P13 · 기본 지침 · 새 독립 실행 2개 · 처음부터 후보 10개 · 관측 3/6/10회





관측: 3회 대비 10회 비용이 실행 1은 14.45%, 실행 2는 30.34% 감소했다.

해석 범위: 이 두 실행의 최종 180초 재검증은 timeout이었다. 그래프는 탐색 중 값이며 원인은 미확정이다.

프롬프트에 전략 지침 한 가지씩을 추가했다

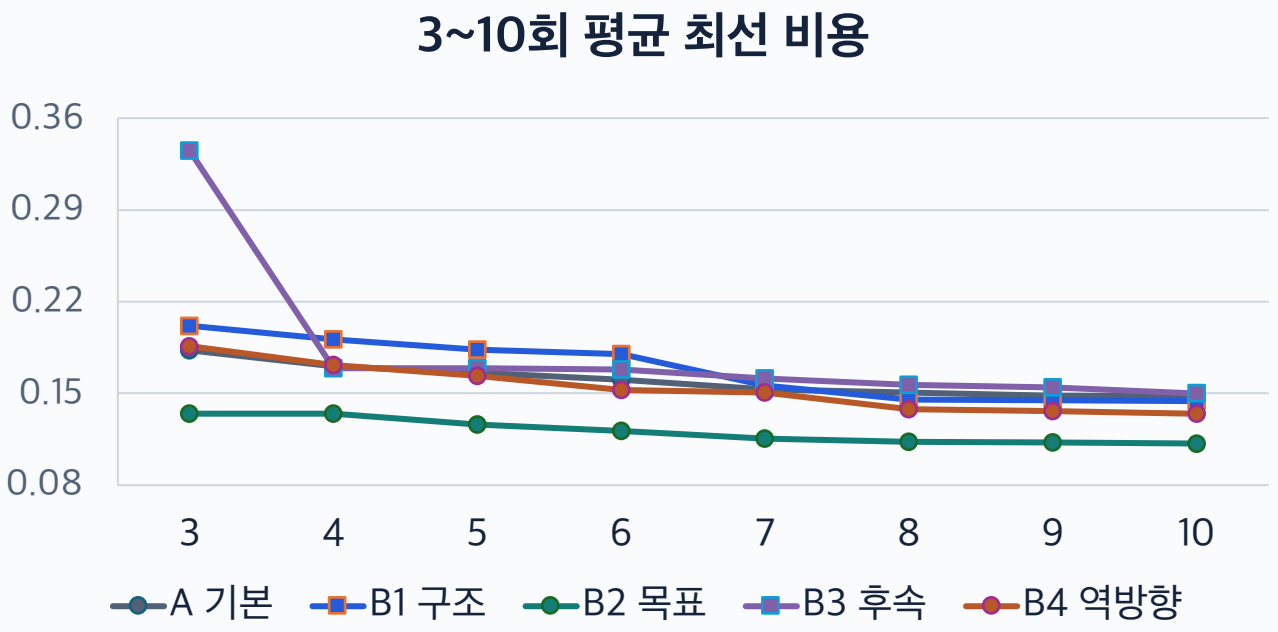
조건	독립변수: A에 추가한 지침
A 기본	기존 기본 지침
B1 구조	강한 중간 명제·함수 귀납 등 다른 증명 구조 탐색
B2 목표	전체 문맥 대신 목표식 중심의 단순화를 검토
B3 후속	새 구조의 직전 후보에 한 번 후속 개선
B4 역방향	현재 목표에서 사용 가능한 lemma를 거꾸로 적용

고정: 문제별 환경·기준값·10후보·피드백·메모리·420초 제한

P13과 P01 각각 5조건 × 독립 실행 2개 · 한 지침이 실제 수정 종류를 하나로 제한하지는 않음

P13은 B2의 10회 평균 비용이 가장 낮았다

P13 · 조건별 독립 실행 2개 · 각 10후보 · 비용 원본=1, 낮을수록 좋음



조건	10회 평균	두 실행의 10회 값
A	0.1478	0.1463 / 0.1493
B1	0.1441	0.1142 / 0.1740
B2	**0.1118**	**0.0998 / 0.1237**
B3	0.1499	0.1541 / 0.1457
B4	0.1345	0.1460 / 0.1229

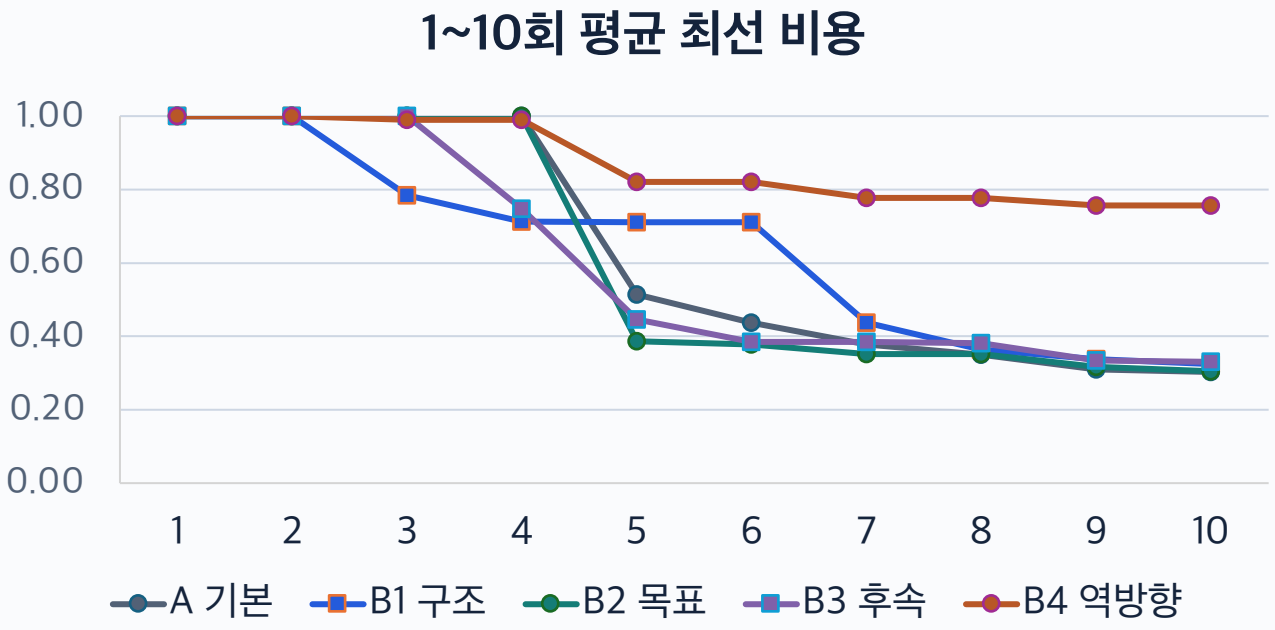
유효 80/100 · 최종 검증 10/10

관측: B2 평균 0.1118은 A 0.1478보다 24.40% 낮았다.

해석 범위: 조건당 2회 탐색 표본이다. 통계적 우위나 다른 문제에서의 우위를 입증하지 않는다.

P01은 기존 A의 10회 평균 비용이 가장 낮았다

P01 · 조건별 독립 실행 2개 · 각 10후보 · 비용 원본=1, 낮을수록 좋음



조건	10회 평균	두 실행의 10회 값
A	**0.3029**	**0.2922 / 0.3136**
B1	0.3245	0.3292 / 0.3197
B2	0.3048	0.3133 / 0.2962
B3	0.3304	0.2823 / 0.3786
B4	0.7566	0.9725 / 0.5407

유효 67/100 · 최종 검증 10/10

관측: B2 평균 0.3048은 A 0.3029보다 0.62% 높아 P13과 같은 이득을 보이지 않았다.

해석 범위: 조건당 2회이며 P01은 개발 문제다. 평균과 단일 최적 후보를 구분한다.

새 P13 후보는 HB가 낮아도 종합 비용은 높았다

P13 · 새 지침 실험의 단일 최적 B2-r1 · 기존 제출본은 과거 동일 환경 대조 측정

항목	기존 제출본	새 실험 최적
증명 토큰	259	311
raw HB	2,931,231	2,755,270
길이 / 원본 1,769	0.1464	0.1758
HB / 원본 115,674,908	0.0253	0.0238
종합 비용 (원본=1)	**0.0859**	**0.0998**

관측: HB는 약 6.00% 낮아졌지만 52토큰 늘어 결합 비용은 기존 대비 16.23% 높았다.

해석 범위: 기존 제출본은 이번 조건에 동시 배정한 run이 아니다. 코드 차이의 구간별 인과효과도 분리하지 않았다.

오류 정보의 선택과 구조를 함께 바꿨다

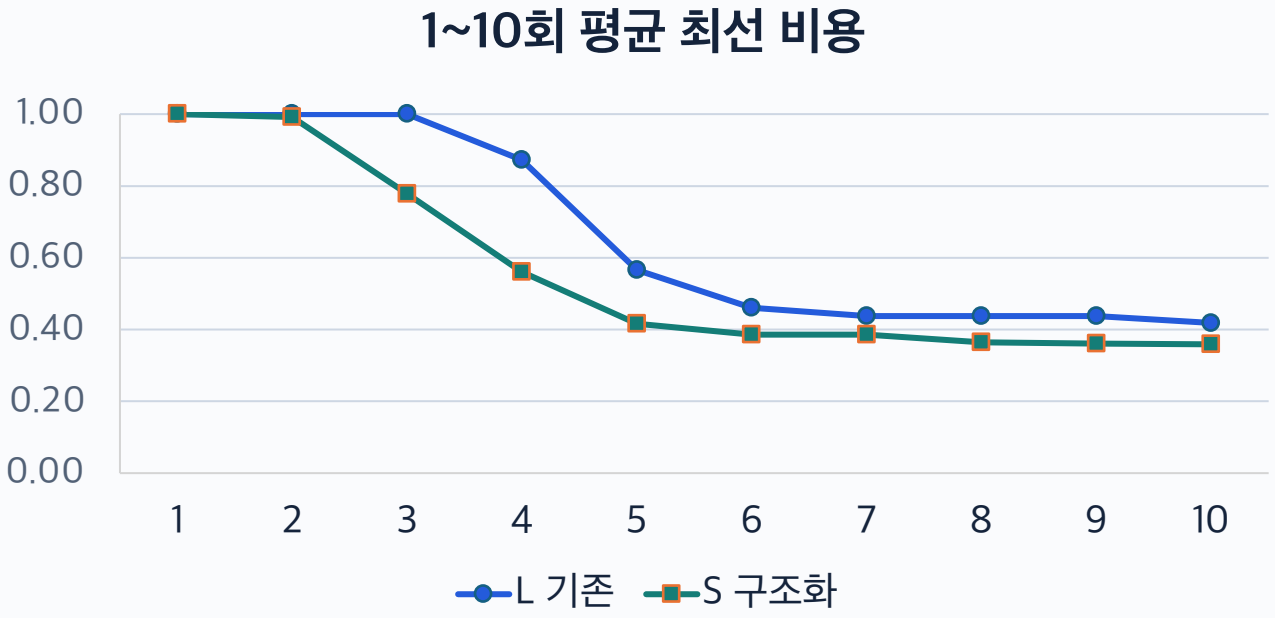
정책	실패한 일반 컴파일 뒤에 전달하는 details
L 기존	기존 평가기 로그 일부를 직렬화한 뒤 잘라 전달
S 구조화	첫 오류와 관련 목표·주변 가정을 선택해 완전한 JSON으로 구성

공통 상한은 오류 피드백 details 1,600자이며 전체 프롬프트 상한이 아니다

고정: 같은 기본 프롬프트·10후보·메모리·420초 제한
S는 필드별 추가 제한도 사용했다. JSON 문법만의 효과를 분리한 실험은 아니다.

P01 표본에서 구조화 피드백의 비용이 낮았다

P01 · L/S 각각 독립 실행 2개 · 각 10후보 · 비용 원본=1, 낮을수록 좋음



조건	3회 평균	6회 평균	10회 평균
L	1.0000	0.4607	0.4184
S	0.7776	0.3852	0.3588

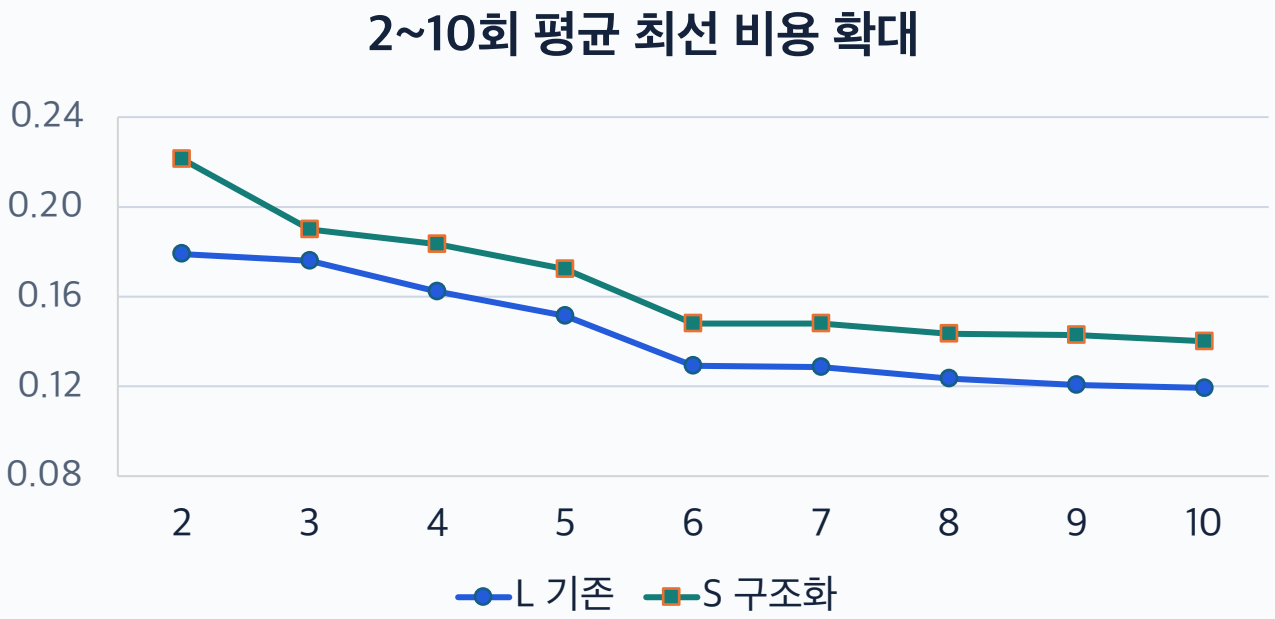
10회 비용의 두 실행 값
L 0.4537 / 0.3830
S 0.3592 / 0.3584

관측: 10회 평균 비용 14.23% 감소, 3회 내 개선 실행 0/2에서 1/2. 초반 유효 평균은 둘 다 1.5/3.

해석 범위: 조건당 2회 개발 문제다. 초반 비용 개선과 컴파일 유효율 개선은 다른 관측이다.

P13 표본에서는 기존 피드백의 비용이 낮았다

P13 · L/S 각각 독립 실행 2개 · 각 10후보 · 비용 원본=1, 낮을수록 좋음



조건	3회 평균	6회 평균	10회 평균
L	0.1761	0.1292	0.1193
S	0.1898	0.1480	0.1401

10회 비용의 두 실행 값
L 0.1368 / 0.1018
S 0.1588 / 0.1214

관측: 10회 평균 비용은 S가 17.41% 높았고, 3회 내 개선 실행은 두 조건 모두 2/2였다.

해석 범위: 3회 이전 L은 오류 노출이 없고 S는 각 1회였다. 초기 경로가 달라 인과효과를 단정하지 않는다.

하네스 결과의 세 가지 구분

최종 timeout은 초기 P13 확장 2개 실행에 한정됐다

실험 묶음	실행 수	유효 / 제안 후보	비용 개선 실행	최종 통과 실행
초기 P01	2	3 / 6	0 / 2	2 / 2
초기 P13	2	4 / 6	2 / 2	2 / 2
P13 예산 확장	**2**	**13 / 20**	**2 / 2**	**0 / 2**
P13 지침 비교	10	80 / 100	10 / 10	10 / 10
P01 지침 비교	10	67 / 100	10 / 10	10 / 10
P01 오류 피드백	4	30 / 40	4 / 4	4 / 4
P13 오류 피드백	4	33 / 40	4 / 4	4 / 4

P01 초기의 최종 통과는 원본 선택본에 대한 결과 · 최종 timeout 두 건의 원인은 미확정

관측한 차이를 지침의 보편적 우위로 해석할 수 없다

확인한 관측	이 기록만으로 확정하지 못한 것
조건당 두 실행의 비용·유효 후보·최종 상태	통계적으로 입증된 우위, 새 문제에서의 일반 성능
같은 오류 로그의 정보 선택·구성 정책 차이	JSON 형식만의 효과, 오류별 순수 인과효과
저장 기록·파일 hash·선택 replay의 일치	새 모델 생성의 동일성, OS 격리, 같은 벽시계 시간
180초 final timeout과 후속420초 성공	초기 timeout의 원인, 시간 상한 단일 변수의 효과

OpenRouter 비교 미실시 · 정확한 backend·seed·내부 모델 호출·요금 미관측

Astra 탐색은 구조 가설을 찾는 별도 연구였다

단계	확인한 문제	남긴 성과
1차	점수 산식과 과거 후보 선택	제출할 최선 후보와 다음 탐색의 출발 후보를 따로 보존
2~3차	귀납·중간 명제·정리 재사용	P01·P02·P03·P14 개선
4~7차	낮은 점수 문제의 구조와 실제 이식	P08·P11·P12 전 버전 검증
HB 집중·심화	남은 비용의 원인과 표현 대조	P11 추가 개선, 실제 정리 전이

하네스 비교와 접근 정보·예산이 달라 모델·정책의 직접 우열 비교로 쓰지 않는다

1~7차 자유 탐색과 HB 연구 두 차례 · 통제된 A/B 정책 실험이 아님

한 버전 검증과 필수 버전 검증을 구분했다

검증 범위	확인한 것	이번 연구의 예
축소 모형	단순화한 가정과 문맥에서 아이디어를 시험	P07·P10의 일부 새 구조
주 환경 전체 원문	한 Lean 버전의 원래 전체 소스에서 검증	최신 P11 450토큰, Lean 4.31
필수 버전 전부	**문제에서 지정한 각 Lean 버전에서 검증**	**P11 7차 473토큰, 4.29·4.30·4.31**

이 발표의 ‘전 버전’ = 해당 문제에 지정된 필수 버전 전부

버전 3개 통과와 같은 버전에서 측정 3회는 서로 다른 검증

절감률·호환율 평균으로 환산 점수를 계산했다

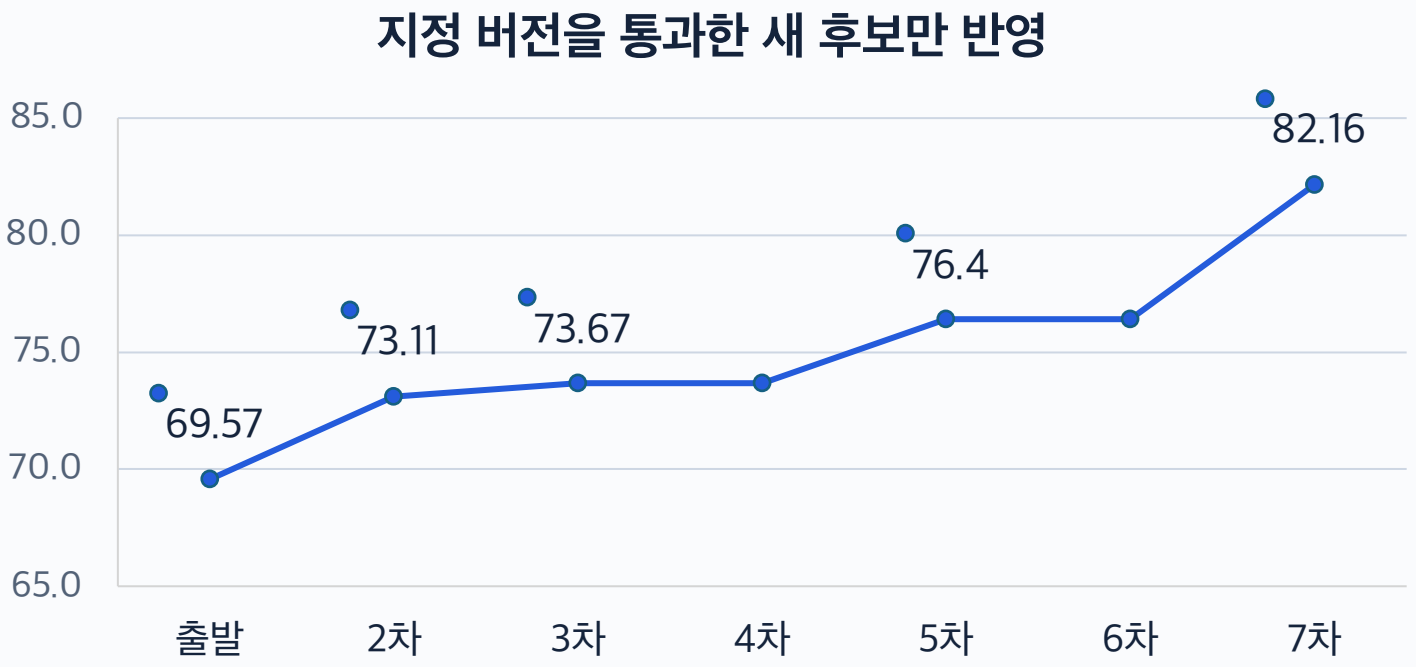
환산 점수 = (길이 절감률 + HB 절감률 + 버전 호환율) ÷ 3

설명용 후보	길이 절감	HB 절감	버전 호환	환산 점수
원본	0%	0%	100%	33.33점
앞의 후보 A	**80%**	**90%**	**100%**	**90점**

후보 A의 종합 비용 0.15와 환산 점수 90점은 같은 후보의 다른 지표

다음 그래프는 15문제 점수의 평균 추정 · 로컬 비율 반영이며 공식 재제출 결과는 아님

7개 새 후보의 반영 평균 추정은 82.16점이었다



82.16점

출발 69.57점 대비 +12.59점

과거 후보 회수까지 가정 83.96점

15문제 기준표에 지정 버전 검증 후보만 교체한 추정 · 공식 재제출과 최신 4.31 후보 반영은 미실시

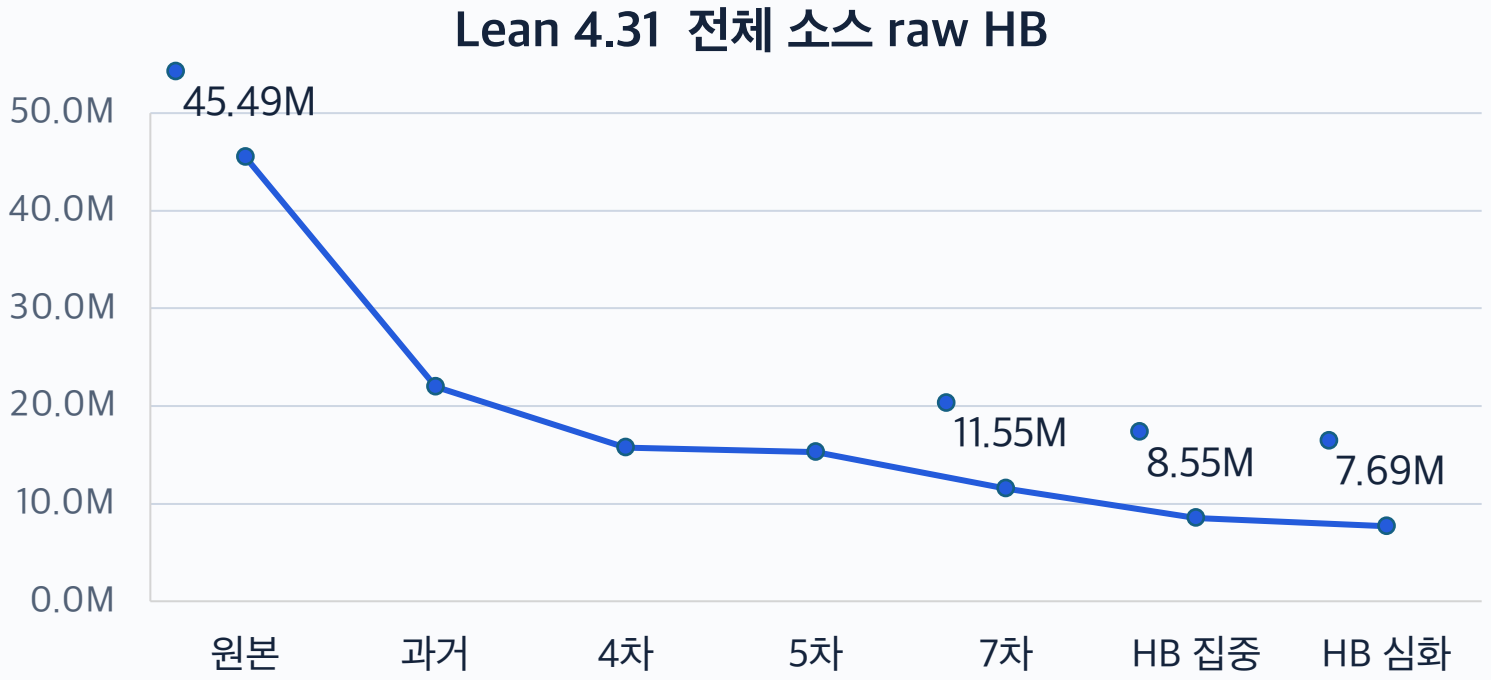
7개 문제에서 필수 버전 검증을 마쳤다

문제	토큰	원본 대비 HB 감소	지정 버전	점수 이전 / 새
P01	32	74.48%	1/1	65.08 / 88.08
P02	19	87.90%	1/1	62.66 / 93.11
P03	78	93.61%	3/3	84.37 / 86.26
P08	**185**	**71.87%**	**4/4**	**34.39 / 75.47**
P11	**473**	**74.60%**	**3/3**	**40.58 / 83.26**
P12	**362**	**57.68%**	**3/3**	**33.33 / 76.97**
P14	55	99.34%	2/2	92.66 / 98.74

HB는 각 주 환경의 원본 대비 감소율 · 지정 버전 수와 같은 환경의 측정 반복 수는 다름

P11은 후속 연구에서 HB를 추가로 33.49% 줄였다

P11: 다항식의 접기 연산과 평가의 관계를 증명하는 정리



33.49%

7차 후보 이후
누적 추가 HB 감소

토큰 473 / 493 / 450
후속 두 연구는 4.31만 검증

M=100만 raw HB · 후속 확정 후보는 각 3회 중앙값 · 최신 후보는 4.31만 검증

같은 증명 항의 생성 비용도 달랐다

목표: α의 값이 존재함 (Nonempty α) · 무관 instance 128개

증명 본문	raw HB 중앙값
exact ⟨default⟩	218,070
exact ⟨@default α inst⟩	**163,494**

25.03% 감소 · 컴파일 후 저장된 증명 항 표현은 동일

타입만 명시 218,392 / instance만 지정 163,642

Lean core 통제 사례, 각 조건 새 프로세스 3회 · 실제 다른 정리에서는 exact가 더 비쌌음

다른 실제 정리에서도 작업을 없애 HB를 줄였다

대상 정리	바꾼 작업	원문 대비 HB 감소	토큰
다항식 차수 상계	**자동 탐색을 직접 근거로 대체**	**96.51%**	**42 / 27**
리스트 멤버십	filterMap에 필요한 증인값을 직접 전달	74.53%	9 / 30
확률 상계	**덧셈 소거·상계 연결·미사용 제거**	**22.04%**	**1,253 / 965**
Fin 곱	정의상 같은 등식을 직접 사용	4.78%	82 / 91

HB 최선에서 토큰이 늘기도 함 · 길이와 HB가 서로 유리한 후보를 함께 보존

Lean 4.31 전체 원문, 각 조건 3회 중앙값 · 확률 보조 정리 개선은 P12 점수에 미합산

관측은 보존하고 정책 제안은 후속 비교로 검증한다

관측	하네스에 반영할 제안
문제별로 달랐던 지침·피드백 효과	작은 대조 실험으로 채택 여부 판단
구조를 바꾼 후보와 후속 변형의 개선	제출할 최선 후보와 분기별 탐색의 출발 후보를 따로 보존
이미 가진 증거를 찾거나 변환하는 비용	직접 증인값·정리를 전달하고 자동화의 목표를 작게 구성
같은 최종 항의 서로 다른 생성 비용	소스·문맥·환경을 보존하고 실측 비교

남은 검증: 최신 P11의 다른 필수 버전, P07·P10 실제 이식, 후보 통합과 정책 대조

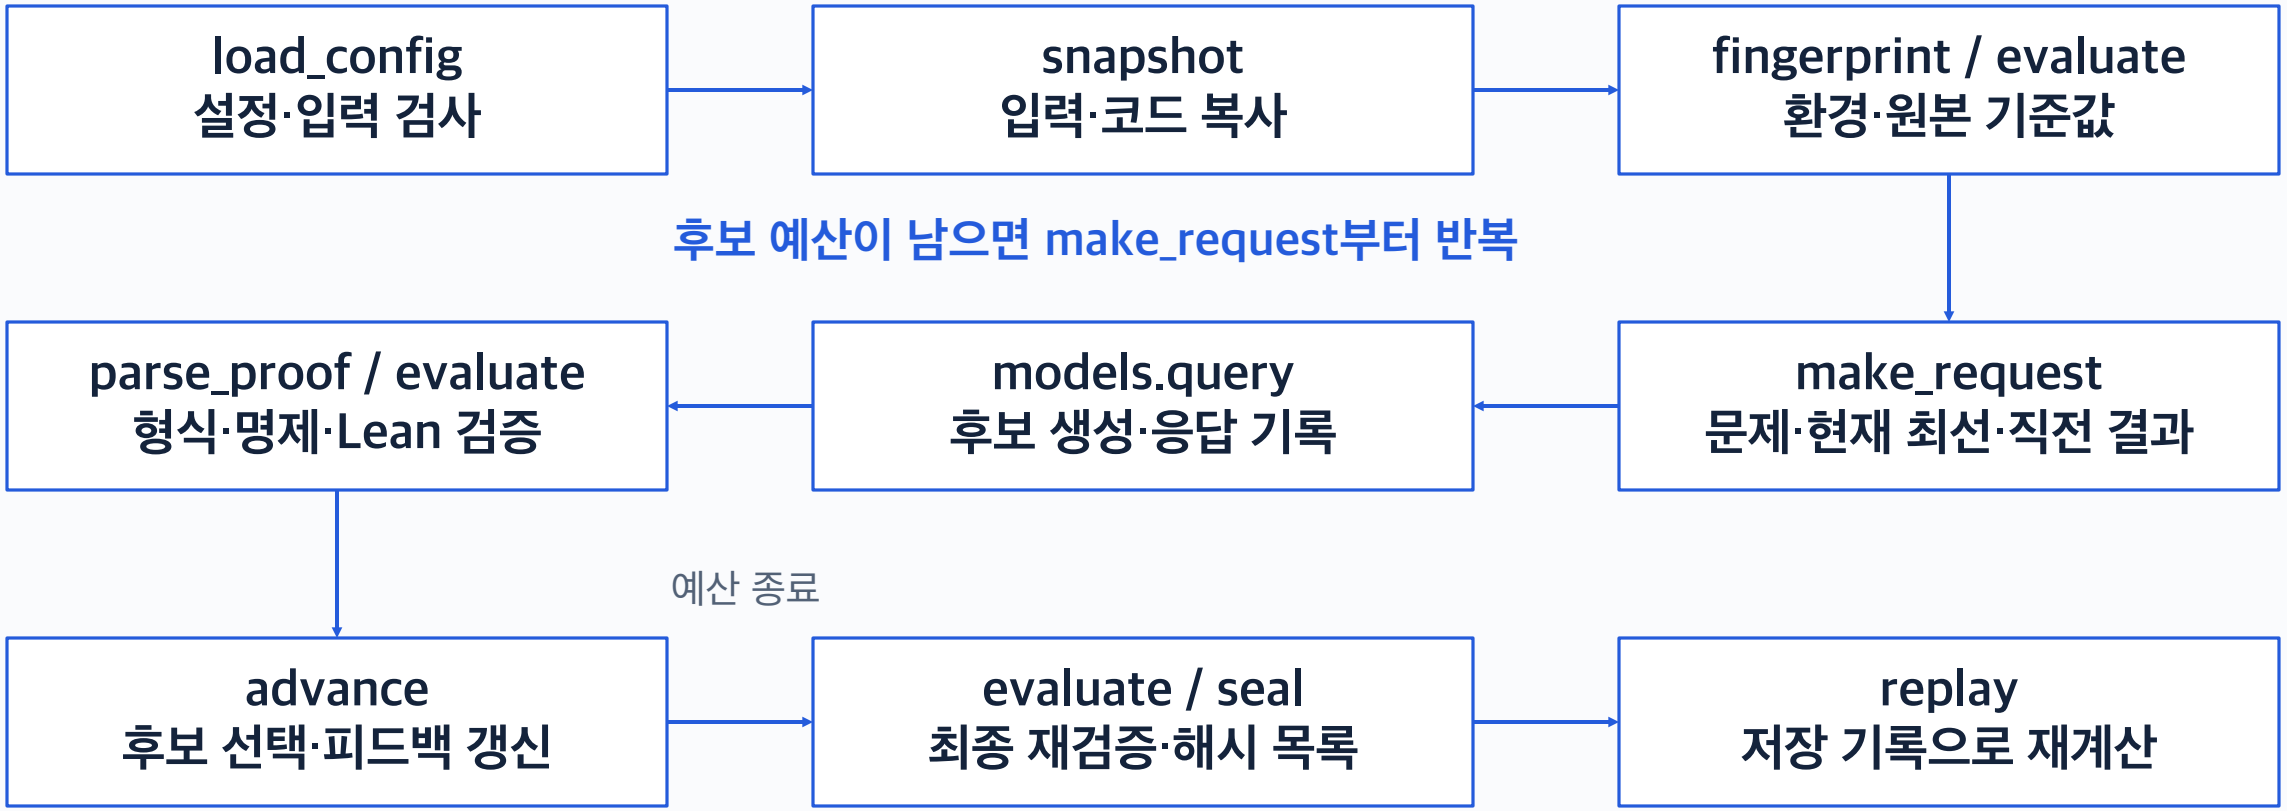
OpenRouter 비교 미실시 · 단일 경로 6회와 서로 다른 3전략 2회씩 비교는 후속 제안

모듈마다 입력·검증·선택·기록의 책임을 나눴다

함수·모듈	실제 역할
load_config / load_problem	설정·경로·명제·예산 검증
snapshot / fingerprint	입력 고정, compiler·라이브러리·코드 식별
evaluate	금지 구문·원문 컴파일·공리·HB 측정
make_request / models.query	현재 상태를 문맥으로 구성하고 응답 보존
parse_proof / advance	본문 파싱, 유효 후보의 결합 비용으로 best 갱신
seal / replay	최종 검증·해시 봉인, 저장된 선택·상태 전이 재계산

저장 기록 replay와 새 모델 생성의 재현성은 별도 관측

구현에서는 후보 생성과 검증 함수를 분리했다



기본 API 하네스 흐름. 실문제 어댑터는 동일한 검증·선택 함수를 재사용

문제마다 명제·라이브러리·원본 분모를 고정했다

조건	P01	P13
문제	substOldPostSubset	putnam_1964_a4
라이브러리	Strata	Mathlib
commit	451e5f047bafa010d178856db76c00029bfa4d7f	2df2f0150c275ad53cb3c90f7c98ec15a56a1a67
Lean 버전	4.26.0	4.26.0
후속 공통 원본 토큰	313	1,769
후속 공통 원본 raw HB	5,173,306	115,674,908

원래 statement·import·prefix/suffix를 유지 · commit 문자열은 저장 environment.lock.json 기준

실행 사이는 분리하고 실행 안의 탐색 문맥은 유지했다

항목	메모리·접근·응답 정책
실행 사이	새 에이전트 문맥, 부모 대화·다른 실행 결과·과거 제출본을 제공하지 않음
실행 안	에이전트 대화 유지, 요청에는 원본·현재 최선·직전 후보와 피드백·예산
접근 범위	지정 request와 제공 source만 열람, 다른 후보·네트워크·임의 탐색 제한
후보 형태	JSON proof 필드에 완성된 by 본문 하나, 본문 최대 16,000자
공유 환경	compiler·라이브러리 읽기 전용 사용 정책으로 공유, OS 격리는 아님

정확한 backend·숨은 시스템 문맥·sampling seed·내부 호출 수는 관측하거나 고정하지 못함

옵션 -T와 초 단위 timeout은 서로 다른 제한이다

설정	고정한 값	의미
-j	1	Lean 파일 처리 스레드 수
-M	4096	Lean 메모리 상한, MB 단위
-T	200000	task당 할당 횟수 기반의 결정적 작업량 제한
하네스 timeout	180초 / 420초	Lean invocation의 벽시계 시간 상한
평가·최종 검증	일반 1회 + 계측 3회	계측 중앙값 사용, 종료 때 선택본 별도 재검증

초기·P13 예산 확장은 180초, 후속 비교는 사전 고정 420초 · -T200000은 200,000초가 아님

A의 기본 프롬프트는 명제 보존과 비용 개선을 요청했다

저장된 A 원문 1/2 · P13·P01 공통 · 영어 원문을 그대로 표시

Refactor the supplied Lean proof while preserving the exact theorem statement.
Return exactly one JSON object: {"proof":"by\n ..."}.
The proof field is a complete replacement tactic proof body, not a declaration.
Use only the supplied problem and feedback. No shell, filesystem, network,
delegation, additional declarations, sorry, admit, axioms, native_decide,
executable metaprogramming, or changes to Lean options.
Only the harness runs Lean and measures candidates.
Minimize the local score: half the sum of proof-token and raw-heartbeat ratios
relative to the original. This is a local experimental metric, not an official score.
Attempt one improvement or repair. A short valid proof can be retained as best.

proof 필드는 선언 전체가 아닌 증명 본문 · 이 원문에서 local score는 발표의 종합 비용을 뜻함

A의 실행 지침은 10후보와 접근 범위를 고정했다

저장된 A 원문 2/2 · 오류 피드백 비교도 같은 A 원문을 사용

This is an unmetered Codex-subagent experiment. Exactly ten proof proposals per independent trial. All pro posals, including invalid ones, consume one step. No delegation, network, shell exploration, or past-result ac cess. Read only the assigned request and input/source.lean; write responses only in your assigned directory. Use the provided worker command for verification. Do not alter the harness, problem, context, source, runti me, metrics, or other trials. A proof must not refer to the target theorem itself.

후보 실패도 한 회차를 소비 · 추가 탐색·위임·과거 결과 접근·하네스 변경을 제한

B1과 B2는 서로 다른 추가 전략 지침이었다

각 B 프롬프트 = A 원문 + “Strategy guidance for this run:” + 아래 추가 원문

B1 추가 원문

Before shortening syntax, consider a stronger local invariant, induction aligned with recursive definitions, or bac
kward application of an available higher-level lemma. Test a structural alternative when the supplied context su
pports it.

B2 추가 원문

When simplifying a goal, consider simplifying only the goal with the relevant local facts instead of repeatedly sim
plifying the entire local context. Keep broader simplification when the measured combined score favors it.

B3와 B4도 A에 각각 한 지침만 더했다

각 B 프롬프트 = A 원문 + “Strategy guidance for this run:” + 아래 추가 원문

B3 추가 원문

If latest explores a materially different proof structure, consider using the next proposal for one focused repair o r refinement of latest before returning to best, even when latest is invalid or currently worse. Allow at most one such follow-up per structural change. It consumes an ordinary proposal within total_steps and grants no addition al attempts.

B4 추가 원문

Try applying an available lemma backwards from the current goal with apply, refine, or exact, rather than first co nstructing a large typed intermediate result. Let the target infer arguments where reliable, while retaining annot ations needed to avoid ambiguity.

구조화 details는 전체 상한과 필드별 상한을 함께 썼다

필드	초기 문자 상한	추출·축소 규칙
message	1,100	첫 오류의 메시지를 우선 보존
location	220	실행 경로를 <RUN>으로 정규화
case	120	첫 목표와 관련된 case
goal	500	첫 관련 목표 블록
local_context	650	관련 문맥의 마지막 12줄

완전한 JSON으로 직렬화한 details 전체가 1,600자를 넘으면 필드를 더 줄인다

초기와 확장은 예산을 각각 3회·10회로 안내했다

초기 원문 발췌

Exactly three proof proposals per independent trial.

P13 확장 원문 발췌

Exactly ten proof proposals per independent trial.

10회 실행의 3·6회 지점은 별도 예산 안내로 다시 시작한 실행이 아니다

P01 초기 실행은 실패 후보까지 예산에 포함했다

P01 · 기본 지침 · 독립 실행 2개 · 각 3후보 · 비용 원본=1

실행 / 회차	검증 상태	토큰	raw HB	후보 자체의 비용
P01-r1 / 1	무효	—	—	계측값 제외
P01-r1 / 2	무효	—	—	계측값 제외
P01-r1 / 3	유효	33	12,281,932	1.2398
P01-r2 / 1	무효	—	—	계측값 제외
P01-r2 / 2	유효	30	12,263,465	1.2332
P01-r2 / 3	유효	31	12,246,853	1.2332

표의 비용은 후보 자체의 값 · 본문 그래프의 “그때까지 최선 비용”과 구분

P13 초기 실행은 실패 후보까지 예산에 포함했다

P13 · 기본 지침 · 독립 실행 2개 · 각 3후보 · 비용 원본=1

실행 / 회차	검증 상태	토큰	raw HB	후보 자체의 비용
P13-r1 / 1	유효	539	5,093,870	0.1744
P13-r1 / 2	무효	—	—	계측값 제외
P13-r1 / 3	유효	415	3,335,984	0.1317
P13-r2 / 1	유효	634	5,617,597	0.2035
P13-r2 / 2	유효	618	5,555,026	0.1987
P13-r2 / 3	무효	—	—	계측값 제외

표의 비용은 후보 자체의 값 · 본문 그래프의 “그때까지 최선 비용”과 구분

P13 확장은 8회 이후에도 최선을 갱신하지 못한 실행이 있었다

회차	실행 1 비용	직전 대비 감소	실행 2 비용	직전 대비 감소
1	1.0000	기준	1.0000	기준
2	0.1803	0.8197	0.1713	0.8287
3	**0.1732**	**0.0071**	**0.1566**	**0.0147**
4	0.1732	0.0000	0.1481	0.0085
5	0.1540	0.0192	0.1474	0.0008
6	**0.1515**	**0.0025**	**0.1432**	**0.0041**
7	0.1515	0.0000	0.1422	0.0010
8	0.1515	0.0000	0.1091	0.0331
9	0.1481	0.0033	0.1091	0.0000
10	**0.1481**	**0.0000**	**0.1091**	**0.0000**

원본=1, 낮을수록 좋음 · 감소는 비용의 절대 차이 · 두 선택본의 최종 재검증은 timeout

P13 지침 비교는 실행별 편차를 남겼다

P13 · 각 실행 10후보 · 3/6/10회 누적 최선 비용 · 원본=1

실행	3회	6회	10회	유효/10	토큰	선택 raw HB	최종
A-r1	0.1623	0.1519	0.1463	9/10	452	4,295,585	통과
A-r2	0.2034	0.1688	0.1493	8/10	423	6,888,338	통과
B1-r1	0.1889	0.1644	0.1142	10/10	360	2,887,802	통과
B1-r2	0.2142	0.1957	0.1740	7/10	528	5,720,822	통과
B2-r1	0.1208	0.1081	0.0998	7/10	311	2,755,270	통과
B2-r2	0.1483	0.1343	0.1237	9/10	389	3,182,031	통과
B3-r1	0.5139	0.1824	0.1541	7/10	477	4,466,174	통과
B3-r2	0.1562	0.1544	0.1457	9/10	445	4,606,947	통과
B4-r1	0.1704	0.1520	0.1460	7/10	424	6,061,587	통과
B4-r2	0.2017	0.1532	0.1229	7/10	351	5,474,294	통과

표의 HB와 비용은 탐색 중 선택 시점 · 최종 재계측의 raw 변동은 final 기록으로 따로 보존

P01 지침 비교도 단일 최적과 평균이 달랐다

P01 · 각 실행 10후보 · 3/6/10회 누적 최선 비용 · 원본=1

실행	3회	6회	10회	유효/10	토큰	선택 raw HB	최종
A-r1	1.0000	0.4942	0.2922	8/10	38	2,394,859	통과
A-r2	1.0000	0.3797	0.3136	7/10	43	2,534,366	통과
B1-r1	1.0000	1.0000	0.3292	6/10	37	2,794,958	통과
B1-r2	0.5676	0.4220	0.3197	7/10	38	2,680,152	통과
B2-r1	1.0000	0.3674	0.3133	7/10	33	2,696,469	통과
B2-r2	1.0000	0.3885	0.2962	8/10	36	2,470,115	통과
B3-r1	1.0000	0.3760	0.2823	7/10	47	2,143,519	통과
B3-r2	1.0000	0.3945	0.3786	8/10	39	3,273,003	통과
B4-r1	0.9794	0.9794	0.9725	3/10	32	9,533,337	통과
B4-r2	1.0000	0.6611	0.5407	6/10	79	4,288,863	통과

표의 HB와 비용은 탐색 중 선택 시점 · 최종 재계측의 raw 변동은 final 기록으로 따로 보존

오류 피드백 비교는 개별 실행 경로가 달랐다

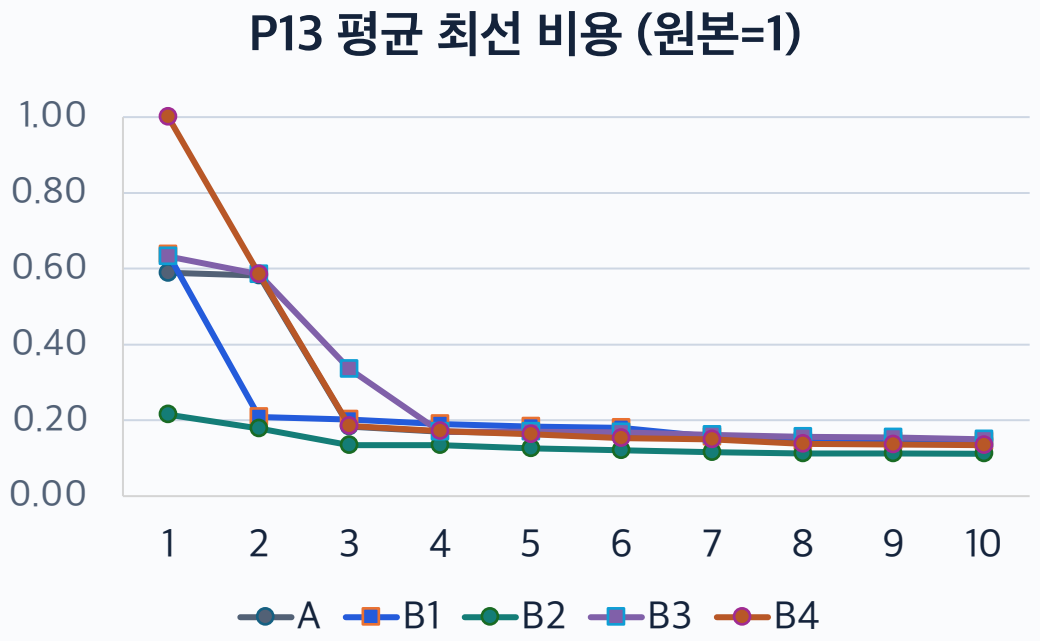
P01·P13 · 각 실행 10후보 · 3/6/10회 누적 최선 비용 · 원본=1

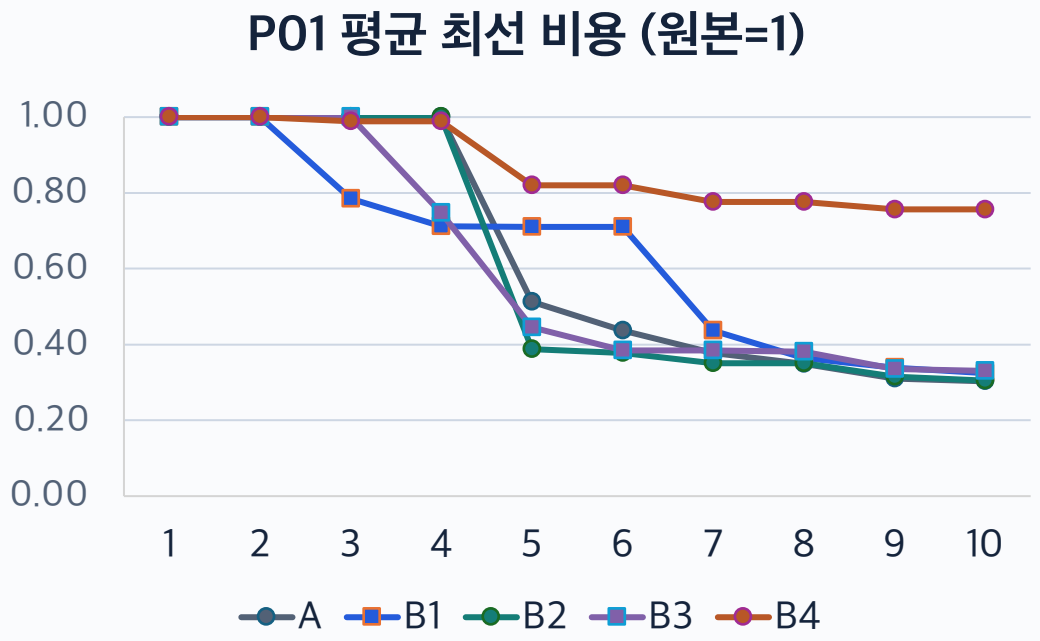
실행	3회	6회	10회	유효/10	토큰	선택 raw HB	최종
P01-L-r1	1.0000	0.5326	0.4537	6/10	40	4,033,440	통과
P01-L-r2	1.0000	0.3887	0.3830	8/10	37	3,351,518	통과
P01-S-r1	1.0000	0.3860	0.3592	8/10	37	3,105,445	통과
P01-S-r2	0.5551	0.3844	0.3584	8/10	36	3,113,500	통과
P13-L-r1	0.1730	0.1461	0.1368	9/10	412	4,710,522	통과
P13-L-r2	0.1791	0.1123	0.1018	8/10	318	2,767,975	통과
P13-S-r1	0.1906	0.1654	0.1588	9/10	468	6,131,861	통과
P13-S-r2	0.1891	0.1306	0.1214	7/10	384	2,983,319	통과

표의 HB와 비용은 탐색 중 선택 시점 · 최종 재계측의 raw 변동은 final 기록으로 따로 보존

지침 비교의 평균 곡선은 누적 최선만 보여준다

P13·P01 각각 조건별 독립 실행 2개 · 각 10후보 · 모든 1~10회 관측





세로축 비용은 낮을수록 좋음 · 실패·무개선 제안은 최선 곡선에서 수평으로 나타남

오류가 발생해야 두 피드백 정책의 차이에 노출됐다

문제·조건	3회 내 유효 평균	3회 내 개선 실행	3회 전 오류 노출 r1 / r2
P01 L	1.50 / 3	0 / 2	1 / 1
P01 S	1.50 / 3	1 / 2	2 / 1
P13 L	2.50 / 3	2 / 2	0 / 0
P13 S	2.00 / 3	2 / 2	1 / 1

P01의 초반 유효 후보 평균은 두 정책 모두 1.5/3이었다

오류별 다음 후보 성공률은 서로 다른 탐색 경로에서 생긴 관측이며 순수 인과효과로 읽지 않음

같은 유한 상태 표현에서도 반복 존재 증명이 달랐다

유계 수열의 연속 네 항을 상태로 보고, 같은 상태가 다시 등장함을 증명

기존 best / 박채원님 제출본

259토큰 · 2,931,231 raw HB

```
let f : ℕ → (Fin 4 → Set.Icc B T) :=
  fun n k => ⟨u (n + k), hB (n + k)⟩
obtain ⟨i, j, hij, he⟩ :=
  Set.finite_univ
    .exists_lt_map_eq_of_forall_mem
      (f := f) (fun _ => Set.mem_univ _)
```

순서가 있는 반복 상태 정리를 직접 호출

목표식 단순화 지침의 최적 후보

311토큰 · 2,755,270 raw HB

```
let f : ℕ → Fin 4 → Set.Icc B T :=
  fun n k => ⟨u (n+k), hB _⟩
obtain ⟨i,j,hne,he⟩ :=
  Finite.exists_ne_map_eq_of_infinite f
rcases lt_or_gt_of_ne hne with h | h
-- 두 경우에서 순서를 맞춰 i < j 구성
```

서로 다른 충돌을 찾고 순서를 따로 구성

새 후보는 HB가 낮지만 52토큰 증가 · 종합 비용 0.0998로 기존 0.0859보다 높음

초기 P13 최적은 유한 범위와 충돌을 따로 증명했다

동일 tokenizer의 소스 구간	기존 제출본	초기 확장 최적
도입	11	11
유한 상태·반복 존재	**57**	**137**
귀납 전개	158	151
주기 추출	33	33
전체 토큰	**259**	**332**

앞부분 80토큰 절감에서 귀납부 7토큰 증가를 상쇄한 차이 · 구간별 HB 인과효과는 미실험

함수 정의에 맞춘 귀납이 PO2의 수동 분기를 줄였다

공통 접근: 순서를 유지한 부분리스트(Sublist)를 증명해 원소 포함 관계(Subset)를 얻음

기존 보관 후보

```
induction post
case' app =>
  unfold extractOldExprVars
  split
```

2차 구조 개선 후보

```
fun_induction
  extractOldExprVars post
```

비교	토큰	raw HB
기존 / 2차	27 / 21	481,648 / 328,658

2차는 직전 후보 대비 HB 31.76% 감소 · 3차 최종 후보는 19토큰 / 326,116 raw HB

P11은 알려진 fiber의 witness를 직접 전달했다

목표: qMap(fiberMap b) = y · fiberMap이 만든 점의 소속 증거를 직접 전달

이전 493토큰 후보 / fiber 관계 재구성

```
have h_res :=
  is_fiber_iff_generates_quotient_point
    𝔽q β i (steps := 1) (by omega)
    (x := fiberMap b) (y := y).mpr (by
      rw [
pointToIterateQuotientIndex_qMap_total_fiber_eq_self])
rw [h_res]
```

최신 450토큰 후보 / 직접 증거 사용

```
have h_res :=
  generates_quotient_point_if_is_fiber_of_y
    𝔽q β i 1 (Nat.succ_le_of_lt i.isLt)
    (fiberMap b) y ⟨b, rfl⟩
exact (congrArg Subtype.val h).symm.trans
  (congrArg Subtype.val h_res).symm
```

다른 결합 변경: 정의 전개 지연, 투영 등식 연결, 기존 경계 증명·인덱스 재사용

결합 후보의 전체 정리에서 10.14% 추가 감소 · 각 코드 조각의 독립 효과는 아님

HB 최저 후보가 종합 비용 최저 후보와 다를 수 있다

리스트 멤버십 후보	토큰	raw HB	종합 비용 (원본=1)
원문	**9**	**268,538**	**1.0000**
짧은 대안	24	68,968	1.4617
HB 최저	**30**	**68,391**	**1.7940**

HB 최저 후보는 처리 비용을 줄였지만 소스는 길어졌음

표의 종합 비용은 같은 50:50 산식을 적용한 추가 계산
길이와 HB의 장단점이 남는 대안(Pareto 후보)을 함께 보존

clear·helper·직접 term은 항상 비용을 줄이지 않았다

같은 목표 안의 변경	관측한 HB 변화
Nat 가설 128개, omega 앞 clear	96.20% 감소
같은 Nat 문맥, 직접 증명 앞 clear	30.45% 증가
Prop 가설 128개, omega 앞 clear	7.48% 증가
무관 instance 128개, infer_instance 앞 clear	54.13% 증가
실제 다항식 정리, apply를 fully-applied exact로	6.27% 증가

지우는 비용을 탐색 절감이 회수하는지 확인 · 닫힌 helper도 바깥 문맥을 자동 제거하지 않음

앞의 여덟 문제는 후보 검증 상태가 서로 달랐다

문제	처음 제출	전 버전 반영	조건부 회수	새 후보 상태
P01	**65.08**	**88.08**	**88.08**	**새 전 버전 검증**
P02	**62.66**	**93.11**	**93.11**	**새 전 버전 검증**
P03	**84.37**	**86.26**	**86.26**	**새 전 버전 검증**
P04	91.25	91.25	91.32	기존·과거 후보
P05	68.49	68.49	75.47	기존·과거 후보
P06	76.52	76.52	76.52	기존·과거 후보
P07	51.36	51.36	69.84	새 구조 이식 남음
P08	**34.39**	**75.47**	**75.47**	**새 전 버전 검증**

전 버전 반영 평균 82.16 / 조건부 회수 평균 83.96 · 공식 재제출 아님

나머지 일곱 문제도 같은 기준으로 점수를 구분했다

문제	처음 제출	전 버전 반영	조건부 회수	새 후보 상태
P09	85.10	85.10	85.10	기존·과거 후보
P10	70.76	70.76	70.76	새 구조 이식 남음
P11	**40.58**	**83.26**	**83.26**	**새 전 버전 검증**
P12	**33.33**	**76.97**	**76.97**	**새 전 버전 검증**
P13	94.26	94.26	95.67	기존·과거 후보
P14	**92.66**	**98.74**	**98.74**	**새 전 버전 검증**
P15	92.76	92.76	92.76	기존·과거 후보

전 버전 반영 평균 82.16 / 조건부 회수 평균 83.96 · 공식 재제출 아님

최신 P11은 3회 확인했지만 다른 두 버전 검증이 남았다

후보	토큰	raw HB 중앙값	검증 범위
7차 r7_direct_goal	473	11,554,959	4.29 / 4.30 / 4.31
HB 집중 c13	493	8,552,201	4.31만
HB 심화 d23	**450**	**7,685,353**	**4.31만**

최신 d23 독립 측정 3회
7,685,350 / 7,685,356 / 7,685,353

전체 원문 컴파일·대상 공리 검사 통과 · 최신 후보의 다른 두 pin은 아직 미검증

각 수치에서 원본 조건·코드·기록으로 내려갈 수 있다

하네스	.worktrees/arena-feedback-summary-20261025/ experiments/first-harness-jwkweon/
Astra 리캡	recap-20261025/ RECAP / RESULTS / JOURNEY / LESSONS
HB 연구 코드	insights-20261025-heartbeats-deep/ best_declarations / RESULTS.json / REPRODUCE.ko.md

각 슬라이드 발표자 노트에 원본 파일과 해석 범위 수록 · 기준일 2026.10.25